

Four-volume 与 Gaussian Splatting 方法

1 方法

1.1 任务定义与总体流程

给定由四个角点子孔径图像组成的 2×2 稀疏光场，目标是在保持空间分辨率的同时，重建任意目标角分辨率 $A \times A$ 的稠密光场，其中训练和测试支持 $A \in \{3, \dots, 9\}$ 。将输入的 SAI (sub-aperture image) 拼接表示记为 $x \in \mathbb{R}^{B \times 1 \times (2S) \times (2T)}$ 。首先，ASR 特征提取器将其转换为

$$X = \text{FE}(x) \in \mathbb{R}^{B \times C \times 2 \times 2 \times S \times T}, \quad C = 64. \quad (1)$$

下文中， B 表示 batch 大小， C 表示特征通道数， S, T 表示单个子孔径图像的高和宽， A 表示目标角分辨率。小写 u, v 是角坐标，小写 s, t 是空间坐标。除特别说明外，坐标均已归一化到 $[-1, 1]$ ，而大写字母表示张量或其尺寸。随后，ASR (arbitrary-scale reconstruction) 特征模块中的 Four-volume 从 X 构造四个互补的三维体特征，并由 GS (Gaussian Splatting) 隐式解码器对每个目标视角进行像素级重建。Four-volume 负责在不同坐标子空间中保存光场结构，GS 则根据目标视角与输入角点的几何关系，预测一组局部二维高斯并将其散射到输出图像。

1.2 Four-volume 特征表示

四个坐标子空间。 将光场特征 X 的维度写作 (u, v, s, t) ，其中 (u, v) 是角坐标， (s, t) 是空间坐标。代码中的四个体分别沿一个坐标轴进行注意力池化，得到

$$\begin{aligned} \mathcal{V}_{uvs} &= \text{Enc}_{uvs}(\text{Pool}_t(X')) \in \mathbb{R}^{B \times C \times 2 \times 2 \times S}, \\ \mathcal{V}_{uvt} &= \text{Enc}_{uvt}(\text{Pool}_s(X')) \in \mathbb{R}^{B \times C \times 2 \times 2 \times T}, \\ \mathcal{V}_{ust} &= \text{Enc}_{ust}(\text{Pool}_v(X')) \in \mathbb{R}^{B \times C \times 2 \times S \times T}, \\ \mathcal{V}_{vst} &= \text{Enc}_{vst}(\text{Pool}_u(X')) \in \mathbb{R}^{B \times C \times 2 \times S \times T}. \end{aligned} \quad (2)$$

这里 X' 是加入坐标条件后的特征（见下文），Pool 不是固定平均，而是由一个可学习查询 token 驱动的多头注意力池化。符号 Enc_j 表示第 j 个体对应的三维卷积残差编码器，负责在池化后进一步提炼局部体结构。因此，每个体沿被消去的轴聚合信息，同时保留其余三个轴的显式结构。

坐标条件。 为避免不同轴排列在数值上不可区分，首先在归一化坐标网格 $\xi = (u, v, s, t) \in [-1, 1]^4$ 上计算一个可学习的坐标嵌入向量

$$P_\theta(\xi) = W_2 \text{ReLU}(W_1 \xi), \quad X' = X + P_\theta(\xi), \quad (3)$$

其中 $P_\theta(\xi) \in \mathbb{R}^C$ 是由坐标 ξ 生成的 C 维位置提示， W_1, W_2 是 $4 \rightarrow C \rightarrow C$ 的线性映射， θ 表示这些可学习参数。它不直接预测图像，而是把当前位置编码成一个特征向量，并加到对应位置的视觉特征上。这样，后续网络能够区分“同一外观位于哪个角度和空间位置”。该嵌入沿 batch 维度广播。

注意力池化与体编码。 该模块将沿待池化轴的一组特征 token 汇聚为一个代表性 token。对于待池化轴上的 token 序列 $\mathcal{T} \in \mathbb{R}^{L \times C}$ ，其中 L 是该轴的 token 数、 C 是每个 token 的通道数，定义一个可学习的查询 token $\mathbf{q}_0 \in \mathbb{R}^C$ 。首先用序列均值构造查询向量：

$$\mathbf{q} = \text{mean}_{\ell=1}^L(\mathcal{T}_\ell) + \mathbf{q}_0, \quad (4)$$

其中 $\mathbf{q}$ 是送入注意力层的查询, mean 沿待池化轴求平均。然后将归一化后的 $\mathbf{q}$ 作为注意力机制的 query, 将归一化后的 token 序列 $\mathcal{T}$ 作为 key, 并将原始 token 序列 $\mathcal{T}$ 作为 value。换言之, $\mathbf{q}$ 用来计算“应该从序列中关注哪些 token”的权重。注意力输出为

$$\mathbf{z} = \text{MHA}(\text{LN}(\mathbf{q}), \text{LN}(\mathcal{T}), \mathcal{T}) + \mathbf{q}, \quad (5)$$

$\mathbf{z}$ 是融合了轴向上下文的池化 token。最后使用前馈网络进一步变换:

$$\bar{\mathbf{z}} = \text{FFN}(\text{LN}(\mathbf{z})) + \mathbf{z}. \quad (6)$$

这里 MHA、LN 和 FFN 分别表示多头注意力、层归一化和前馈网络。 $\bar{\mathbf{z}}$ 被重新排列为对应的三维体, 并经过两个 $3 \times 3 \times 3$ 卷积、LeakyReLU 和残差连接的‘VolumeResidualBlock’。该设计将沿轴的长序列压缩为一个内容自适应的体 token, 而不是在视角间使用固定插值。

固定模板 (可选)。 编码后的四个体可以分别加上可学习模板

$$\tilde{\mathcal{V}}_j = \mathcal{V}_j + \Theta_j, \quad j \in \{uvs, uvt, ust, vst\}, \quad (7)$$

其中默认模板尺寸为

$$\Theta_{uvs}, \Theta_{uvt} \in \mathbb{R}^{1 \times C \times 2 \times 2 \times 64}, \quad \Theta_{ust}, \Theta_{vst} \in \mathbb{R}^{1 \times C \times 2 \times 64 \times 64}, \quad (8)$$

初始化标准差为 $0.1/\sqrt{C}$ 。这里 Θ_j 表示与体特征同形状的可学习模板。

1.3 跨体交互与任意角分辨率字段生成

轴向 Transformer。 四个体先分别通过‘VolumeAxialTransformerBlock’, 沿其三个体轴依次进行多头自注意力。对任一体 $\mathcal{V} \in \{\mathcal{V}_{uvs}, \mathcal{V}_{uvt}, \mathcal{V}_{ust}, \mathcal{V}_{vst}\}$ 的第 r 个轴, 记重排后的 token 序列为 $\mathcal{A}_r$, 则

$$\mathcal{A}_r \leftarrow \mathcal{A}_r + \text{MHA}_r(\text{LN}_r(\mathcal{A}_r), \text{LN}_r(\mathcal{A}_r), \mathcal{A}_r), \quad \mathcal{V} \leftarrow \mathcal{V} + \text{FFN}(\text{LN}(\mathcal{V})). \quad (9)$$

该操作在每个体内部传播长程依赖, 同时保持体的轴语义不变。

跨体交互。 将 uvs 和 uvt 的完整体 token, 以及将 ust 和 vst 的空间维自适应平均池化到不超过 32×32 后的 token 拼接起来, 再加入一个由输入特征全局均值得到的 LF token。每类体和 LF token 分别加上可学习的类型嵌入后进行一次跨体多头注意力: 下面用 $\mathcal{Y}_j$ 表示加入类型嵌入后的第 j 类体 token, $\mathcal{Y}_{\text{LF}}$ 表示 LF (light-field) 全局 token。 $\mathcal{Y}$ 是它们沿 token 维拼接后的序列。

$$\mathcal{Y} = \text{Concat}(\mathcal{Y}_{uvs}, \mathcal{Y}_{uvt}, \mathcal{Y}_{ust}, \mathcal{Y}_{vst}, \mathcal{Y}_{\text{LF}}), \quad \hat{\mathcal{Y}} = \mathcal{Y} + \text{MHA}(\text{LN}(\mathcal{Y}), \text{LN}(\mathcal{Y}), \mathcal{Y}), \quad \mathcal{Y}^+ = \hat{\mathcal{Y}} + \text{FFN}(\text{LN}(\hat{\mathcal{Y}})). \quad (10)$$

从 $\mathcal{Y}^+ - \mathcal{Y}$ 经体类型对应的线性层投影为增量并加回原体。池化 token 在加回前使用三线插值恢复到原体尺寸。该交互使四种二维切片对同一目标视角形成一致的上下文, 并支持逐体分支消融。

坐标条件基字段上采样。 Four-volume 编码后只包含输入的 2×2 角采样。为支持任意目标角分辨率 A , 我们为每个体学习一个可查询的基字段, 通过目标角坐标动态组合基函数, 而不是对角维进行固定插值。设第 j 个体经过卷积后得到 CK 个通道, 沿其角轴求平均并重排为

$$B_j \in \mathbb{R}^{B \times G \times C_g \times K \times P_j}, \quad C_g = C/G, \quad G = 8, \quad K = 16. \quad (11)$$

其中 P_j 是保留的空间位置数, uvs 、 uvt 、 ust/vst 分别对应 S 、 T 和 ST 。因此, $B_{j,g,:k,p}$ 是位置 p 处第 g 组的第 k 个基向量。

对于二维角体 uvs/uvt , 查询坐标为 $q = (u, v)$ 。对于单轴角体 ust/vst , 查询坐标为 $q = u$ 或 $q = v$ 。所有坐标均从 $[-1, 1]$ 的均匀网格中取得。每个角轴的 cell 尺寸为

$$\Delta q = \frac{2}{A-1}, \quad \mathbf{r}_q = [q, \Delta q]. \quad (12)$$

Continuous angular field synthesis




图 1: 坐标条件基字段上采样示意图。体特征经基函数编码后, 由目标角坐标和内容条件共同预测组合系数, 从而生成任意角分辨率的字段。

将坐标和 cell 输入四频率 Fourier 编码

$$\gamma(q, \Delta q) = \left[\mathbf{r}_q, \left\{ \sin(2^k \pi \mathbf{r}_q), \cos(2^k \pi \mathbf{r}_q) \right\}_{k=0}^3 \right]. \quad (13)$$

同时, 对体特征在所有角轴和空间位置求平均, 经线性层得到内容向量 $c_j \in \mathbb{R}^C$ 。将 c_j 与每个查询点的 $\gamma(q, \Delta q)$ 拼接, 系数解码器输出 GK 个系数 $a_{j,g,k}(q)$ 。第 g 个通道组的字段值为

$$\mathbf{f}_{j,g}(q, p) = \sum_{k=1}^K a_{j,g,k}(q) B_{j,g,:,k,p}, \quad \mathcal{F}_j(q, p) = \text{Concat}_{g=1}^G \mathbf{f}_{j,g}(q, p). \quad (14)$$

该过程使基函数保存场景和空间结构, 系数则根据目标角坐标和输入内容动态选择基函数。最终, uvs/uvr 生成 $\mathcal{F}_{uvs} \in \mathbb{R}^{B \times C \times A \times A \times S}$ 和 $\mathcal{F}_{uvr} \in \mathbb{R}^{B \times C \times A \times A \times T}$, 而 ust/vst 生成 $\mathcal{F}_{ust}, \mathcal{F}_{vst} \in \mathbb{R}^{B \times C \times A \times S \times T}$ 。给定目标视角 (u^*, v^*) 和空间位置 (s, t) , GS 从四个字段提取并拼接互补上下文, 随后与 anchor feature 和几何编码共同预测 Gaussian 参数。

1.4 输入视角锚定的 Gaussian Splatting 解码器

四个体字段的目标视角采样。Four-volume 上采样后得到四个可以查询的字段。对目标视角 (u^*, v^*) , 解码器分别读取

$$\mathbf{f}_{uvs}(s) = \mathcal{F}_{uvs}(u^*, v^*, s), \quad \mathbf{f}_{uvr}(t) = \mathcal{F}_{uvr}(u^*, v^*, t), \quad (15)$$

$$\mathbf{f}_{ust}(s, t) = \mathcal{F}_{ust}(u^*, s, t), \quad \mathbf{f}_{vst}(s, t) = \mathcal{F}_{vst}(v^*, s, t). \quad (16)$$

前两个字段包含完整目标角坐标 (u^*, v^*) , 分别保留一个空间轴, 因此需要沿缺失的空间轴广播。后两个字段只依赖一个角轴, 直接提供目标角对应的空间切片。于是, 在空间位置 (s, t) , 四个字段共同形成

$$\mathbf{h}(s, t; u^*, v^*) = [\mathbf{f}_{uvs}(s), \mathbf{f}_{uvr}(t), \mathbf{f}_{ust}(s, t), \mathbf{f}_{vst}(s, t)] \in \mathbb{R}^{4C}. \quad (17)$$

该上下文对当前目标视角是共享的, 但会与四个输入角点各自的 anchor feature 分别组合, 形成四条 anchor-pixel 解码路径。换言之, 每个空间位置有 4 个 anchor, 每个 anchor 又预测 M 个局部高斯, 默认 $M = 4$, 因此一个输出像素最多接收 $4M$ 个高斯的贡献。

几何条件与 MLP 输入。输入角点的物理角坐标为

$$\{(-1, -1), (-1, 1), (1, -1), (1, 1)\}. \quad (18)$$

目标网格中的坐标先定义在 $[-1, 1]$ ，再乘以 $A/(A-1)$ 得到与输入角点一致的物理坐标。对第 r 个 anchor，令其坐标为 (u_r, v_r) ，目标坐标为 (u^*, v^*) ，则

$$\Delta_r = (u^* - u_r, v^* - v_r), \quad d_r = \|\Delta_r\|_2, \quad \hat{\Delta}_r = \frac{\Delta_r}{\max(d_r, \epsilon)}. \quad (19)$$

由此构造 11 维几何向量

$$g_r = [u_r, v_r, u^*, v^*, \Delta u_r, \Delta v_r, |\Delta u_r|, |\Delta v_r|, d_r, \hat{\Delta} u_r, \hat{\Delta} v_r]. \quad (20)$$

它同时编码了 anchor 和目标视角的位置、两者的水平与垂直差异、欧氏角距离以及从 anchor 指向目标的单位方向。因此，第 r 条解码路径在每个空间位置的输入为

$$\mathbf{z}_r(s, t) = [\mathbf{h}(s, t; u^*, v^*), \mathbf{x}_r(s, t), g_r] \in \mathbb{R}^{5C+11}, \quad (21)$$

其中 $\mathbf{x}_r(s, t) \in \mathbb{R}^C$ 是第 r 个输入角点的 anchor feature。该拼接说明了四个体字段负责提供目标角上下文，anchor feature 负责保留已观测视角的局部内容，几何向量负责告诉网络当前需要从哪个输入视角迁移到哪里。

Gaussian 参数预测与中心移动。 一个四层、每层宽度为 256 的 MLP 对每个 $\mathbf{z}_r(s, t)$ 输出 M 组参数。第 m 个高斯的原始输出写为

$$(\hat{\delta}_s, \hat{\delta}_t, \hat{\sigma}_s, \hat{\sigma}_t, \hat{\rho}, \hat{a}, \mathbf{v})_{r,m}, \quad \mathbf{v}_{r,m} \in \mathbb{R}^C. \quad (22)$$

其中， $\hat{\delta}_s, \hat{\delta}_t$ 是中心偏移的预激活值，决定高斯从当前空间位置向两个空间轴移动多少， $\hat{\sigma}_s, \hat{\sigma}_t$ 决定两个轴上的覆盖尺度， $\hat{\rho}$ 决定两个轴的相关性， $\hat{a}$ 是 opacity 的预激活值， $\mathbf{v}$ 是高斯携带的 C 维内容向量。前六项是标量，最后一项是待散射的特征向量。经过有界或非负变换后，得到

$$\begin{aligned} \delta_{r,m} &= \frac{2\ell_r}{\min(S, T)} \tanh(\hat{\delta}_{r,m}), \\ \sigma_{s,r,m} &= \text{softplus}(\hat{\sigma}_{s,r,m}) + 0.5, \quad \sigma_{t,r,m} = \text{softplus}(\hat{\sigma}_{t,r,m}) + 0.5, \\ \rho_{r,m} &= 0.95 \tanh(\hat{\rho}_{r,m}), \quad \alpha_{r,m} = \text{sigmoid}(\hat{a}_{r,m}). \end{aligned} \quad (23)$$

其中 ℓ_r 是由 anchor 与目标角距离决定的像素范围，采用

$$\ell_r = 8 + \text{clip}\left(\frac{d_r}{\sqrt{8}}, 0, 1\right) (16 - 8) \text{ pixels}. \quad (24)$$

由于 δ 使用归一化空间坐标表示，式中的 $2/\min(S, T)$ 将像素范围换算到 $[-1, 1]$ 。随后，归一化中心 $\mu_{r,m}^n = p + \delta_{r,m}$ 被裁剪到 $[-1, 1]^2$ ，其中 $p = (s, t)$ 是当前空间位置，并通过

$$\mu_{r,m}^{\text{px}} = \frac{(\mu_{r,m}^n + 1) \odot (S, T) - (1, 1)}{2} \quad (25)$$

转换为像素坐标。这样，偏移直接改变高斯椭圆的中心。角距离较大的目标视角允许更大的中心移动范围，使 anchor 的局部内容能够覆盖更远的输出位置。

由尺度与相关性确定椭圆形状。 在像素坐标中，两个尺度和相关系数定义协方差矩阵

$$\Sigma_{r,m} = \begin{bmatrix} \sigma_{s,r,m}^2 & \rho_{r,m} \sigma_{s,r,m} \sigma_{t,r,m} \\ \rho_{r,m} \sigma_{s,r,m} \sigma_{t,r,m} & \sigma_{t,r,m}^2 \end{bmatrix}. \quad (26)$$

对任意邻域像素 $y = (y_s, y_t)$ ，令 $e = y - \mu_{r,m}^{\text{px}}$ ，其 Mahalanobis 距离平方为

$$e^T \Sigma_{r,m}^{-1} e = \frac{1}{1 - \rho_{r,m}^2} \left(\frac{e_s^2}{\sigma_{s,r,m}^2} + \frac{e_t^2}{\sigma_{t,r,m}^2} - \frac{2\rho_{r,m} e_s e_t}{\sigma_{s,r,m} \sigma_{t,r,m}} \right). \quad (27)$$

因此， σ_s 增大时椭圆沿 s 方向变宽， σ_t 增大时沿 t 方向变宽。当 $\rho = 0$ 时，椭圆轴与 s, t 坐标轴对齐，当 $\rho \neq 0$ 时，非对角项使椭圆发生倾斜或旋转。opacity α 不改变椭圆几何形状，而是整体调节该高斯对输出特征的贡献强度。代码采用未显式归一化的二维相关高斯核。由于最终还会对所有高斯权重求和归一化，代码不再单独计算 $1/(2\pi|\Sigma|^{1/2})$ ，因此单个高斯的实际权重为

$$w_{r,m}(y) = \alpha_{r,m} \exp\left[-\frac{1}{2} e^T \Sigma_{r,m}^{-1} e\right] \mathbf{1}[y \in \mathcal{N}_5(\mu_{r,m}^{\text{px}})]. \quad (28)$$

Confidence gate 与局部 Gaussian Splatting. confidence head 对同一 anchor-pixel 输入输出每个高斯的四个 anchor logits $z_{r,m}$, 并沿 anchor 维归一化:

$$c_{r,m} = \text{softmax}_r(z_{r,m}/\tau), \quad \tau = 0.7. \quad (29)$$

因此, 对固定像素和高斯编号, 四个 $c_{r,m}$ 的和为 1。它反映网络认为哪个输入角点更适合解释当前目标视角, 默认直接使用该分配, 也可以与均匀权重按 β 混合。confidence 进入散射权重后得到

$$\tilde{w}_{r,m}(y) = c_{r,m} w_{r,m}(y). \quad (30)$$

实现中每个高斯只访问以 $\mu_{r,m}^{\text{px}}$ 四舍五入位置为中心的 5×5 邻域 $\mathcal{N}_5$ 。对越界邻域位置使用有效性掩码置零, 然后通过 ‘scatter_add’ 按目标像素索引同时累加特征分子和权重分母:

$$\hat{F}(y) = \frac{\sum_{r=1}^4 \sum_{m=1}^M \tilde{w}_{r,m}(y) \mathbf{v}_{r,m}}{\max \left(\sum_{r=1}^4 \sum_{m=1}^M \tilde{w}_{r,m}(y), \epsilon \right)}. \quad (31)$$

分子是所有局部高斯携带的特征向量的加权和, 分母把不同数量、不同 opacity 的高斯贡献归一化, 因而输出仍是 C 维特征。这一步不是在角度维上做插值, 而是在每个目标视角的空间平面上把来自四个 anchor 的局部高斯重新聚合为一个特征像素。

目标光场特征与图像输出。 对每个目标视角重复上述字段查询、参数预测和局部散射, 得到

$$\hat{F} \in \mathbb{R}^{B \times C \times A \times A \times S \times T}. \quad (32)$$

四个角点视角不重新预测, 而是直接复制对应的输入特征, 保证已观测视角不被 GS 分支改变。随后将角度维 (u, v) 展平为 A^2 个视角, 并通过三个 $1 \times 1 \times 1$ Conv3d 和 LeakyReLU 将通道从 $C = 64$ 压缩到 1, 得到 $[B, 1, A^2, S, T]$ 的子孔径图像序列。最后, ‘FormOutput’ 按 u 行、 v 列依次拼接这些子孔径图像, 形成尺寸为 $[B, 1, AS, AT]$ 的 SAI 输出。由此, GS 模块完成了从四个输入角点特征到任意 $A \times A$ 目标光场的空间特征重建, 而最终的像素级光场图像由后续输出映射得到。

1.5 训练目标与实现边界

训练时仅对缺失视角计算重建损失。令 Ω_{miss} 表示去除四个角点后的视角集合, $\hat{I}_{u,v}$ 和 $I_{u,v}$ 分别表示预测图像与真实图像, 则主损失为

$$\mathcal{L}_{\text{L1}} = \frac{1}{|\Omega_{\text{miss}}|} \sum_{(u,v) \in \Omega_{\text{miss}}} \left\| \hat{I}_{u,v} - I_{u,v} \right\|_1. \quad (33)$$

代码还提供可选的 Sobel x/y 梯度 Smooth-L1 正则, 训练前 30 个 epoch 关闭, 再在线性 20 个 epoch 内将权重提升到默认 0.05。该项只作用于缺失视角。